

Intrusion Detection System (IDS) Jaringan Adaptif dengan Continual Model Retraining



Dibuat oleh

Alexander Angelo - 245150201111035

Dosen Pengampu

Rizal Setya Perdana, S.Kom., M.Kom., Ph.D.

1. Identifikasi Masalah & Domain

Di era perkembangan teknologi yang semakin modern ini, Indonesia mengalami peningkatan ketergantungan terhadap infrastruktur digital, baik pada sektor pemerintahan, pendidikan, layanan publik, perbankan, maupun perusahaan. Seiring dengan meningkatnya penggunaan teknologi tersebut, instansi-instansi pemerintahan, maupun swasta turut menghadapi ancaman yang berbahaya, seperti network intrusion, malware, botnet, DoS/DDoS, dan aktivitas jaringan yang tidak wajar.

Permasalahan ini sangat relevan dengan kondisi keamanan siber Indonesia. Berdasarkan Lanskap Keamanan Siber Indonesia 2024 dari BSSN, terdapat 330,5 juta anomali trafik yang terpantau sepanjang tahun 2024. Mirai Botnet menjadi jenis anomali trafik terbesar dengan sekitar 81,3 juta aktivitas, sementara BSSN juga mencatat ratusan notifikasi yang berkaitan dengan anomali trafik. Hal ini yang memperkuat kebutuhan akan suatu pelindung jaringan untuk membantu mengidentifikasi aktivitas jaringan yang berpotensi membahayakan sistem sebelum berkembang menjadi insiden yang lebih besar. Untuk itu, proyek ini bertujuan untuk membangun sebuah *Network Intrusion Detection System* (NIDS) berbasis AI untuk mendeteksi aktivitas jaringan berbahaya secara otomatis.

Salah satu tantangan dalam membangun NIDS adalah perubahan karakteristik lalu lintas jaringan dan pola serangan dari waktu ke waktu. Model yang dilatih menggunakan data historis dapat mengalami penurunan performa ketika menghadapi distribusi atau pola data baru yang berbeda dari data training. Oleh karena itu, sistem deteksi yang hanya mengandalkan model statis berpotensi menjadi kurang efektif dalam menghadapi perubahan pola serangan.

Berdasarkan permasalahan tersebut, proyek ini mengusulkan *Adaptive Network Intrusion Detection System with Continual Model Retraining*, yaitu sistem deteksi intrusi berbasis deep learning yang dilengkapi mekanisme pemantauan performa dan distribusi data. Ketika sudah melewati batas waktu atau terdeteksi perubahan distribusi yang melewati threshold tertentu, sistem akan secara otomatis memicu proses pelatihan ulang (*retraining*) model menggunakan data terbaru. Dengan pendekatan tersebut, model diharapkan dapat mempertahankan kemampuan deteksinya terhadap perubahan karakteristik network traffic tanpa memerlukan proses pelatihan ulang secara manual.

2. Dataset

Dataset yang digunakan untuk proses training, yaitu Dataset UNSW-NB15, merupakan data tabular dengan 49 kolom yang diperoleh secara sekunder melalui platform Kaggle. Dataset ini dibuat oleh IXIA PerfectStorm di Cyber Range Lab of the Australian Centre for Cyber Security (ACCS). Data ini terdiri dari 2.540.044 baris yang merupakan gabungan antara aktivitas jaringan normal riil dan aktivitas jaringan abnormal sintetis. Dataset ini memiliki 9 jenis serangan, yaitu Fuzzers, Analysis, Backdoors, DoS, Exploits, Generic, Reconnaissance, Shellcode, dan Worms. Namun, dalam proyek ini, labelnya akan diubah menjadi biner dengan label “Attack” dan “Normal”, karena sistem hanya perlu mengetahui apakah jaringan tersebut berbahaya atau tidak.

Proses pengambilan data pada saat deployment akan menggunakan *Zeek*, yaitu sebuah aplikasi penangkap jaringan pada tingkat *session*/aplikasi, sehingga data bisa di-*capture* secara real-time. Hal ini juga yang akan mendukung proses *Continual Learning* dari model karena data akan terus bertambah. Namun dalam proses training model, proyek ini hanya akan menirukan konsep *Continual Learning* menggunakan data statis sebagai simulasi.

3. Metodologi

3.1 Continual Learning

Strategi *continual learning* pada proyek ini dirancang untuk memungkinkan model *Network Intrusion Detection System* (NIDS) beradaptasi terhadap perubahan karakteristik lalu lintas jaringan tanpa memerlukan pelatihan ulang secara manual. Data jaringan pada saat deployment akan diperoleh secara berkelanjutan menggunakan *Zeek*, sedangkan proses pengembangan dan pengujian model akan menggunakan dataset UNSW-NB15 yang dibagi menjadi beberapa *batch* secara berurutan untuk mensimulasikan kedatangan data baru. Pada tahap deployment, data lalu lintas jaringan akan dikumpulkan secara berkala dan dikelompokkan dalam interval harian, sehingga setiap hari sistem memperoleh batch data baru yang dapat digunakan untuk melakukan monitoring terhadap perubahan distribusi data.

Pada proses *deployment*, data-data yang berasal dari *Zeek* masih belum memiliki label. Oleh karena itu, data harian yang telah dikumpulkan akan divalidasi lebih lanjut di hari esok, terutama untuk lalu lintas jaringan yang diprediksi sebagai berbahaya. Kemudian, proses *continual learning* model akan dipicu setiap minggu untuk melatih ulang menggunakan data-data terbaru yang sudah diberikan label untuk memastikan model tetap diperbarui secara berkala dan tahan terhadap anomali-anomali lalu lintas jaringan yang belum pernah dilihat. Oleh karena itu, perlu adanya *feature engineering* lebih lanjut untuk menyamakan fitur pada dataset UNSW-NB15 dengan data yang diperoleh melalui *Zeek*.

3.2 Metriks/Kriteria Keberhasilan

Kriteria keberhasilan proyek ini dibagi menjadi 3 kategori, yaitu metrik performa model, metrik teknis sistem, dan perubahan metrik saat proses *continual learning*.

3.2.1 Metrik Performa Model

Metrik	Tujuan
Recall	Mengukur kemampuan model dalam mendeteksi serangan sebenarnya (<i>True Negative</i>)

F1-Score	Mengukur keseimbangan antara <i>precision</i> dan <i>recall</i>
PR-AUC	Mengevaluasi kemampuan klasifikasi pada data yang tidak seimbang

Tabel 3.1 Metrik performa model dan tujuannya

Metrik yang akan diutamakan adalah Recall karena model harus bisa mendeteksi serangan yang berbahaya, meskipun dengan *trade-off* dimana beberapa lalu lintas jaringan normal juga ikut terprediksi sebagai serangan. Selain itu, PR-AUC juga digunakan untuk melihat performa model dalam menghadapi data yang *imbalance*.

3.2.2 Metrik Teknis Sistem

Selain performa model, sistem juga dievaluasi dari sisi kemampuan menjalankan inference dan retraining secara efektif dan efisien.

Metrik	Tujuan
Inference Latency	Waktu yang dibutuhkan bagi model untuk menghasilkan prediksi
Network Throughput	Jumlah aliran jaringan yang bisa diproses dalam satu satuan waktu
Model Retraining Duration	Waktu yang dibutuhkan untuk menyelesaikan proses retraining

Tabel 3.2 Metrik teknis sistem dan tujuannya

3.2.3 Metrik Continual Learning

Fokus utama dari proyek ini adalah untuk melihat kemampuan model beradaptasi pada data baru. Oleh karena itu, evaluasi terhadap model tidak hanya dilakukan sekali saja pada model akhir, namun akan dievaluasi pada beberapa tahap selama proses continual training menggunakan dataset UNSW-NB15.

Metrik yang akan digunakan meliputi:

- perubahan Recall sebelum dan setelah retraining
- perubahan F1-Score sebelum dan setelah retraining
- perubahan PR-AUC
- jumlah retraining yang dilakukan

3.3 Rancangan Arsitektur


Arsitektur sistem dirancang untuk mencakup keseluruhan siklus MLOps, mulai dari data ingestion, preprocessing, version control, model training, model registry, deployment, inference, monitoring, hingga continual retraining.

Sistem dibagi menjadi dua pipeline utama:

1. Inference Pipeline: Mengumpulkan dan menangani data jaringan dan menghasilkan prediksi secara berkelanjutan.
2. Continual Learning Pipeline: Memproses data harian, mengelola data berlabel, dan menjalankan retraining apabila pemicu terpenuhi.

3.3.1 Inference Pipeline


Pada tahap deployment, Zeek akan digunakan untuk menangkap lalu lintas jaringan pada tingkat aplikasi/session. Informasi lalu lintas jaringan yang ditangkap kemudian diproses menjadi fitur yang sesuai dengan input model.



Gambar 3.1 Alur Inference Sistem

Inference dapat berjalan secara kontinu, sedangkan hasil prediksi data akan dikumpulkan menjadi satu batch untuk kebutuhan monitoring (harian) dan continual learning (mingguan).

3.3.2 Continual Learning Pipeline



Gambar 3.2 Alur Continual Learning

Setelah data jaringan diprediksi dan dikumpul menjadi 1 kumpulan data harian, akan ada proses validasi label, terutama pada data yang dilabel sebagai serangan (Attack). Setelah data sudah terkumpul selama seminggu, dan jumlah data mencukupi, maka sistem akan melakukan pelatihan ulang pada model, sebelum kemudian men-deploy model baru tersebut.